

计划书模板


(大数据研究院)

1. 问?

- | | |
|------------|-------------------------|
| 1、数据量: | 100g |
| 2、预算: | 50 万 |
| 3、数据存储多久: | 1 年 |
| 4、云主机、物理机: | 云主机 |
| 5、日活: | 100 万 |
| 6、数据源: | 用户行为数据(文件)、业务数据 (Mysql) |
| 7、项目周期: | 4 天 |
| 8、团队多少人: | 7 个 |
| 9、首批指标: | 25 个 |
| 10、未来的规划: | 离线 (未来可能会做实时) |

2. 系统数据流程设计

1.1 集群流程图



1.2 集群框架图



1.3 集群特点

- 1、多数据源对接能力
- 2、离线批量/在线实时处理
- 3、统一的集群管理配置监控平台
- 4、实现用户认证和权限管理, 满足多租户需求

3. 具体版本选型

• Apache 框架版本

产品	版本	特点
Hadoop	3.1.3	
Java	1.8	
DataX	3.0	1. 传输过程在单进程内完成, 不读写磁盘 2. 异构数据库和文件系统数据交换
Flume	1.9.0	1. 支持断点续传 2. 官方 HDFS 接口 3. 自带事务, 不容易丢数据
Maxwell	1.25.0	支持断点续传

Kafka	2.4.1	支持多个消费者接口
Hive	3.1.2	支持大规模的数据计算
Spark	3.0.0	1. 基于内存运算, 比 Hadoop 快 100 倍 2. 支持 Java, Python 和 Scala 的 API 3. 提供了统一的解决方案 极易方便和 Hadoop 环境进行融合
MySQL	5.7.16	
DolphinScheduler	2.3.0	1. 支持 HA 2. 调度工作流 3. 支持暂停、恢复、补数操作 4. 失败会发电子邮件提醒 5. 可以监控任务状态
Zookeeper	3.5.7	

4. 服务器选型

4.1 机器成本考虑

4.1.1 物理机

内存	128G
CPU	20 核, 40 线程
硬盘	8THDD, 2TSSD
品牌	惠普
报价	4W
寿命	5 年

4.1.2 云主机

内存	128G
CPU	20 核, 40 线程
硬盘	8THDD, 2TSSD
品牌	阿里云
每年	5W

4.2 运维成本考虑

4.2.1 物理机

需要有专门的运维人员

4.2.2 云主机

运维工作由阿里云完成，综合考虑选择阿里云主机

5. 集群规模

5.1 数据量分析

5.1.1 用户行为数据

(1)每天日活跃用户 100 万,每人一天平均 100 条: $100 \text{ 万} * 100 \text{ 条} = 1 \text{ 亿条}$

(2)每条日志约 1k 左右, 每天 1 亿条: $1000000000 / 1024 / 1024 \approx 100\text{G}$

(3)数仓 ODS 层采用 LZ0 存储: 100G 压缩为 5G 左右

(4)数仓 DWD 层采用 LZ0+ORC 存储: 5G 左右

(5)数仓 DWS 层轻度聚合存储: 25G 左右

(6)数仓 ADS 层数据量: 很小,忽略不计

(7)保存 3 副本: $35\text{G} * 3 = 105\text{G}$

(8)半年内不扩容服务器: $105\text{G} * 180 \text{ 天} \approx 19\text{T}$

(9)预留 20%~30%Buf = $19\text{T} / 0.7 \approx 28\text{T}$

5.1.2 Kafka 中数据

(1)每天约 100G 数据*副本(2) = 200G

(2)保存 4 天*200G=800G

(3)预留 30%Buf = $800\text{G} / 0.7 \approx 1\text{T}$

5.1.3 业务数据

(1)每天业务数据 10 万条, 每条数据 1k 左右: $10 \text{ 万} * 1\text{k} \approx 100\text{M}$ 左右

- (2)数仓四层存储: $100M*3 = 300M$
 (3)保存 3 副本: $300M*3 \approx 1G$
 (4)半年内不扩容服务器来算: $1G*180 \text{ 天} \approx 180G$
 (5)预留 20%~30%Buf = $180G/0.7 \approx 250G$

5.1.4 集群总规模

$28T + 1T + 250G \approx 30T$

5.1.5 服务器台数

约 8T*5 台服务器

5.2 集群规划

hadoop100	hadoop101	hadoop102	hadoop103	hadoop104
NameNode	NameNode	DataNode	DataNode	DataNode
ResourceManager	ResourceManager	NodeManager	NodeManager	NodeManager
		JournalNode	JournalNode	JournalNode
		Zookeeper	Zookeeper	Zookeeper
		Kafka	Kafka	Kafka
Hiveserver2	Metastore	hive-client	hive-client	hive-client
Spark		Spark	Spark	Spark
DS-master	DS-master	DS-worker	DS-worker	DS-worker
Maxwell				
mysql				
flume	flume			

5.3 离线测试集群服务器规划

服务器名称	自服务	服务器 Hadoop102	服务器 Hadoop03	服务器 Hadoop104
HDFS	NameNode	√		
	DataNode	√	√	√

	HA	√	√	
Yarn	NodeManager	√	√	√
	Resourcemanager		√	
Zookeeper	Zookeeper server	√	√	√
Flume(采集)	Flume	√	√	√
Kafka	Kafka	√	√	√
Flume(消费)	Flume			√
Hive	Hive	√		
MySQL	MySQL	√		
DataX	DataX	√		
DolphinScheduler	DS-master	√		
	DS-worker	√	√	√
服务器总计		12	8	7

6. 人员配置

组长： 1 名

副组长： 1 名

组员： 5 名

任务职责： 详细见项目计划书



项目安排计划.xlsx

熟悉技能： Hadoop, Hive, Flume, Kafka, DolphinScheduler, Java/Scala, Spark, Sqoop, Zookeeper, Redis, MySQL, Xshell 集群搭建用时

6.1 离线测试集群搭建用时

时间 :0.5 天

6.2 离线正式集群搭建用时

时间 :0.5 天

7. 首批指标查询用时

- 注：首批指标要优先熟悉业务字段，导致首批指标查询用时稍长

7.1 常用指标用时

(来源分析、路径分析、各来源下单、用户变动、用户留存等)

每个指标时间：0.5 天

7.2 临时指标用时

每个指标时间：1.5 天

7.3 活动指标用时

每个指标时间：1 天

7.4 特殊指标用时

(完课综合指标、各学科试听留存统计等等)

每个指标时间：3 天

8. Bug 处理用时

8.1 框架 Bug 处理用时

时间：1 天

8.2 指标 Bug 处理用时

时间：1 天