

[辅助资料]数据生成器与配套数据

极简数据生成器

资料获取

[极简数据生成器.zip](#)

数据生成器使用方式

这个极简数据生成器会根据命令行参数创建一个文件，并在其中不断写入数据

程序功能

1. 从命令行接收一个文件路径参数
2. 从命令行接收一个数据生成间隔时间参数（以毫秒为单位）
3. 在指定路径创建一个文件（如果文件不存在）。
4. 根据指定的间隔时间不断地向文件中写入数据，数据格式如下。

```
{  
  "user_id": int,  
  "event": string,  
  "ts": long  
}
```

其中，ts 是当前时间的戳

如何使用

使用如下命令运行：

```
./dataGenTest_linux64 -path output.json -interval 1000
```

- `-path` 默认值 `data.json`
- `-interval` 默认值 `500`

Spark 练习配套数据

[spark_gpt 配套数据.zip](#)

名称	时间	类型	大小
 orders.txt	2023-05-06 15:45	TXT 文件	1 KB
 story.txt	2023-05-08 14:08	TXT 文件	2 KB
 timestamp.txt	2023-05-06 15:35	TXT 文件	1 KB
 users.txt	2023-05-06 15:45	TXT 文件	1 KB

- `orders.txt` : 模拟的订单数据
- `users.txt` : 模拟的用户数据
- `timestamp.txt` : 模拟的时间戳数据
- `story.txt` : 一个英语短文, 用来做 wordcount